Universidad de Las Américas

FACULTAD DE INGENIERÍA Y CIENCIAS APLICADAS

INGENIERÍA DE SOFTWARE / SISTEMAS DE INFORMACIÓN

APRENDIZAJE AUTOMÁTICO

Código: IIAR0004 | **NRC:** 5414 | **Período:** Semestre 2026 – 2027 (2027-10)

TRABAJO EN CLASE: TALLER DE PREPROCESAMIENTO

Taller: Preprocesamiento y Limpieza de Bases de Datos Clínicas

Tratamiento de Calidad de Datos, Detección de Outliers, Codificación Categórica y Prevención de Data Leakage en Heart Disease

Grupo Asignado:	Group 4 (Entrega Individual)
Estudiante / Autor:	**Carlos Alberto Angulo Pizarro** (carlos.angulo.pizarro@udla.edu.ec)
Docente Titular:	Raúl Paredes, M. Sc.
Fecha de Entrega:	Quito, 14 de octubre de 2026
Repositorio GitHub:	github.com/Elnuget/taller-preprocesamiento...
Google Colab Online:	Clic para abrir en Google Colab

QUITO – ECUADOR

1 Contexto Clínico y Objetivos del Preprocesamiento

Una institución hospitalaria proyecta implementar un sistema inteligente de soporte a la toma de decisiones clínicas basado en Machine Learning, con la finalidad de estimar de forma oportuna la presencia o ausencia de cardiopatía isquémica en pacientes evaluados bajo el protocolo estándar de Cleveland. Para este propósito, el equipo técnico recibe un conjunto de datos histórico (`Heart-Disease-Dirty.csv`) que recopila 14 atributos clínicos y demográficos.

No obstante, la recolección empírica de datos en entornos hospitalarios está sujeta a errores de transcripción, fallos de calibración en sensores y pérdidas de registros. Consecuentemente, el dataset crudo se encuentra severamente contaminado por ruido textual, unidades físicas incrustadas, valores biológicamente imposibles, registros duplicados y omisiones en la variable de supervisión.

Objetivo General: Demostrar la transición metódica desde un conjunto de datos desestructurado e inestable hacia una matriz de características matemáticamente consistente, libre de sesgos y adecuadamente acondicionada para algoritmos predictivos, garantizando la rigurosa prevención de fuga de información (*data leakage*).

Restricción Fundamental de la Práctica: De acuerdo con las especificaciones del taller, se prohíbe de forma terminante entrenar modelos en esta fase; el alcance se circunscribe a la justificación técnica de la ingeniería de datos.

2 Criterio 1: Exploración y Comprensión del Dataset

El dataset crudo presenta una dimensión inicial de **312 registros y 14 variables**. A continuación se resume la caracterización taxonómica de los atributos:

Variable	Naturaleza	Significado Fisiológico y Rango Válido
age	Numérica Continua	Edad en años del paciente [18 – 100].
sex	Binaria	Sexo biológico (1 = Hombre, 0 = Mujer).
cp	Categórica Nominal	Tipo de dolor torácico (0 = Típico, 1 = Atípico, 2 = No anginoso, 3 = Asintomático).
trestbps	Numérica Continua	Presión arterial sistólica en reposo en mmHg [90 – 200].
chol	Numérica Continua	Colesterol sérico en mg/dL [120 – 500].
fbs	Binaria	Glucemia en ayunas > 120 mg/dL (1 = Verdadero, 0 = Falso).
restecg	Categórica Nominal	Hallazgo electrocardiográfico en reposo (0 = Normal, 1 = ST-T anormal, 2 = Hipertrofia).
thalach	Numérica Continua	Frecuencia cardíaca máxima alcanzada en prueba de esfuerzo [60 – 220].
exang	Binaria	Angina de pecho inducida por ejercicio físico (1 = Sí, 0 = No).
oldpeak	Numérica Continua	Depresión del segmento ST inducida por ejercicio vs reposo [0.0 – 6.2].
slope	Categórica Ordinal	Pendiente del segmento ST pico de esfuerzo (0 = Ascendente, 1 = Plano, 2 = Descendente).
ca	Discreta / Ordinal	Número de vasos coronarios principales (0 a 3) visualizados con fluoroscopia.
thal	Categórica Nominal	Prueba de talasemia / perfusión (1 = Normal, 2 = Defecto fijo, 3 = Defecto reversible).
target	Binaria (Supervisión)	Diagnóstico cardiológico: 0 = Paciente Sano, 1 = Cardiopatía Presente.

Tabla 1: Diccionario de variables del protocolo clínico Heart Disease.

Análisis de la Variable Objetivo (`target`): El recuento revela 161 observaciones de la clase positiva (54.2 %) y 136 de la clase negativa (45.8 %) entre los registros etiquetados válidos, evidenciando un problema de clasificación binaria moderadamente balanceado.

3 Criterio 2: Identificación y Tratamiento de Problemas de Calidad

Se detectaron anomalías sistemáticas derivadas de errores de carga y digitación:

1. **Cadenas Textuales y Ruido de Unidades:** En columnas teóricamente numéricas (`age`, `sex`) se identificaron valores como `'ERROR'`, `'unknown'` e incrustaciones de unidades métricas como `'56.0 mg'`. Mediante expresiones regulares y coerción numérica (`pd.to_numeric(errors='coerce')`), las cadenas de texto no válidas fueron convertidas a valores nulos (`NaN`) y los sufijos de unidades fueron purgados.

2. **Registros Duplicados:** Se detectaron **6 filas exactamente idénticas**. Estos registros fueron eliminados mediante `drop_duplicates()`, debido a que la duplicidad artificial de

instancias genera una sobreponderación indebida de ciertas densidades de probabilidad en el espacio de características, introduciendo sesgo de sobreajuste (*overfitting*).

3. **Valores Faltantes en la Variable Objetivo (`target`):** Se identificaron 15 pacientes que carecían de diagnóstico (`NaN` en `target`). **Decisión técnica:** Estas 15 filas fueron purgadas del dataset. Bajo el paradigma de aprendizaje supervisado, no es metodológicamente admisible imputar la variable objetivo, ya que cualquier estimador (moda o modelo auxiliar) inyectaría hipótesis artificiales directamente en la verdad terreno (*ground truth*), distorsionando las métricas de rendimiento clínico (sensibilidad y especificidad).

4. **Estrategia de Imputación de Predictoras:** Para las variables predictoras continuas (`age`, `trestbps`, `chol`, `thalach`, `oldpeak`), se optó por la **mediana muestral**, debido a su robustez frente a la asimetría de las distribuciones biomédicas. Para variables binarias y categóricas (`sex`, `cp`, `fbs`, `restecg`, `exang`, `slope`, `ca`, `thal`), se aplicó la **moda**.

4 Criterio 3: Análisis y Tratamiento de Valores Atípicos e Inconsistencias

En datos clínicos, los valores atípicos se desglosan en dos tipologías: **anomalías de inconsistencia fisiológica** (errores de instrumento) y **casos patológicos extremos reales**.

- **Inconsistencias Fisiológicas Flagrantes:**
  - Se detectó una edad de -**67 años** y valores superiores a 109 años en age.
  - Se identificaron registros con `sex` = -1.0 y 3.49, cuando el dominio es binario estricto $\{0, 1\}$.
  - Se observó `cp` = 7.25, fuera del estándar anatómico $\{0, 1, 2, 3\}$.
  - Se hallaron presiones sistólicas `trestbps` superiores a 310 mmHg.

  Tratamiento: Dichos registros no representan variabilidad biológica sino corrupción de datos. En concordancia con las restricciones del taller (*"no eliminar registros arbitrariamente"*), los valores fuera de rango se transformaron a `NaN` y fueron re-estimados mediante la mediana del atributo.

- **Valores Extremos Verosímiles (Colesterol sérico):** El colesterol presentó niveles máximos de 564 mg/dL. Aunque estadísticamente supera el umbral $Q_3 + 1{,}5 \cdot IQR$, clínicamente corresponde a casos reales de hipercolesterolemia familiar severa, correlacionada de forma directa con cardiopatía. Por ende, estos registros fueron conservados intactos para preservar la señal predictiva del modelo.

5 Criterios 4 y 5: Selección, Transformación y Separación de Variables

5.1 Separación de Predictoras (X) y Variable Objetivo (y)

Se estructuró la partición entre la matriz de características $X \in \mathbb{R}^{n \times 13}$ y el vector de etiquetas $y \in \{0, 1\}^n$:

$$X = \text{Dataset} \setminus \{\texttt{target}\}, \qquad y = \text{Dataset}[\texttt{target}] \tag{1}$$

Justificación Teórica: La variable `target` representa el fenómeno clínico a predecir. Si se mantuviese dentro de X, el modelo aprendería una correlación determinista perfecta e inservible (fuga de etiquetas trivial), anulando la capacidad de inducción matemática en inferencia clínica no observada.

5.2 Codificación de Atributos Categóricos (Encoding)

Las variables categóricas no ordinales no pueden alimentarse como enteros arbitrarios a clasificadores sensibles a magnitudes (regresión logística, redes neuronales, SVM), pues el algoritmo asumiría una relación de orden métrico ficticia (ej. interpretar que $cp = 3$ es tres veces mayor que $cp = 1$).

- Se aplicó **One-Hot Encoding** sobre variables nominales policotómicas (`cp`, `restecg`, `slope`, `thal`) utilizando `drop='first'` para evitar la trampa de las variables ficticias (*dummy variable trap*) y erradicar la colinealidad exacta.
- Las variables binarias naturales (`sex`, `fbs`, `exang`) se mantuvieron en $\{0, 1\}$.

6 Criterios 6 y 7: Partición Train/Test y Prevención de Data Leakage

6.1 División Estratificada de la Muestra

Se realizó la división de los datos antes de cualquier cómputo de escalamiento empleando los siguientes hiperparámetros de partición:

- `test_size = 0.20`: Se reservó el 20 % de las instancias (aproximadamente 60 pacientes) para la evaluación final imparcial, destinando el 80 % al aprendizaje.
- `stratify = y`: Parámetro crítico que fuerza a que la razón de prevalencia de la cardiopatía ($\approx 54\,\%$ positivos, $\approx 46\,\%$ negativos) se replique con exactitud tanto en

el conjunto de entrenamiento como en el de testeo, mitigando sesgos de selección inducidos por muestreos aleatorios desafortunados.

- `random_state = 42`: Establece la semilla pseudoaleatoria que garantiza la reproducibilidad íntegra del experimento.

6.2 Escalamiento y Prevención de Data Leakage

El escalamiento de variables con diferentes escalas dimensionales (por ejemplo, `chol` en cientos de mg/dL frente a `oldpeak` en unidades decimales) es indispensable para evitar que los atributos de mayor varianza numérica monopolicen los gradientes y el cálculo de distancias euclidianas.

$$z = \frac{x - \mu_{\text{train}}}{\sigma_{\text{train}}} \tag{2}$$

Protocolo Estricto contra Data Leakage:

1. El objeto `StandardScaler` se ajustó (`.fit()`) **única y exclusivamente con los datos de entrenamiento (`X_train`)**, deduciendo los parámetros μ_{train} y σ_{train}.
2. El conjunto de evaluación (`X_test`) fue normalizado utilizando el método `.transform()`, empleando la media y desviación estándar de entrenamiento sin recalcular estadísticas sobre el conjunto de test.
3. **Explicación del Riesgo de Data Leakage:** Si se hubiese aplicado el escalador sobre la totalidad del dataset previo al split, la media y varianza global habrían incorporado la distribución de las muestras de prueba. Esta fuga de información otorga al modelo un conocimiento encubierto de la población externa, produciendo métricas de validación artificialmente optimistas que colapsan al desplegar el sistema en un entorno clínico real.

7 Tabla Oficial de Decisiones de Preprocesamiento

A continuación se consolida la matriz de decisiones técnico-metodológicas exigida en la rúbrica oficial de la cátedra:

Problema	Decisión Adoptada	Justificación Técnica y Fundamentación
Valores Faltantes	Imputación por mediana en cuantitativas; moda en categóricas. Eliminación de filas con `target` nulo.	La mediana minimiza el error absoluto sin verse afectada por asimetrías. Imputar la variable supervisada introduciría etiquetas artificiales espurias.
Duplicados	Remoción de 6 registros idénticos con `drop_duplicates()`.	Elimina la redundancia que causa sobreajuste y distorsión de la distribución conjunta de probabilidades.
Outliers / Inconsistencias	Conversión a `NaN` de edades negativas, sexos y dolores de pecho fuera de rango; re-imputación por mediana/moda.	Se preservan las filas para no perder el resto de información clínica no corrompida del paciente.
Variables Eliminadas	Ninguna variable fue descartada; se conservaron las 13 predictoras.	Cada atributo del protocolo de Cleveland posee validación biológica demostrada en cardiología preventiva.
Variables Categóricas	Clasificación en binarias (`sex`, `fbs`, `exang`) y nominales (`cp`, `restecg`, `slope`, `thal`).	Impide que modelos lineales asuman graduación o precedencia matemática en variables de cualidad cualitativa.
Encoding	One-Hot Encoding con `drop='first'` sobre nominales.	Evita la singularidad en matrices de covarianza (*dummy trap*) y facilita la interpretabilidad de los coeficientes.
Normalización / Scaling	Estandarización con `StandardScaler` fit exclusivo sobre `X_train`.	Homogeniza el espacio métrico impidiendo que el colesterol domine a la depresión ST, blindando el testeo contra *data leakage*.

Tabla 2: Matriz oficial de decisiones de preprocesamiento de datos.

8 Pregunta de Reflexión Teórica

¿Por qué un buen modelo de Machine Learning depende de un adecuado proceso de preprocesamiento de datos?

Fundamentación Teórica del Grupo 4:
En Machine Learning rige de manera inexorable el principio epistemológico *"Garbage In, Garbage Out"* (si ingresan datos deficientes, el algoritmo producirá inferencias erróneas). Un modelo matemático de optimización es simplemente una máquina estadística orientada a minimizar una función de pérdida; no posee criterio intuitivo ni conocimiento biológico para discernir si una edad negativa de -67 años o una presión de 310 mmHg constituye un error de captura o un patrón patológico real. Si estos datos contaminados no son corregidos, los estimadores estadísticos (medias, matrices de correlación y gradientes estocásticos) se desviarán significativamente, induciendo fronteras de decisión completamente deformadas.
Asimismo, en modelos geométricos (como máquinas de vectores de soporte, k-vecinos más cercanos o redes neuronales), la ausencia de un escalamiento adecuado hace que variables con magnitudes físicas elevadas (ej. colesterol sérico ≈ 250 mg/dL) eclipsen por completo el impacto de variables con rangos reducidos (ej. depresión ST $\approx 0{,}8$), perdiendo variables de pronóstico vital. Finalmente, un diseño riguroso del flujo de preprocesamiento —separando el entrenamiento de la prueba previo a cualquier transformación— es el único mecanismo que previene la fuga de datos (*data leakage*), asegurando que la precisión calculada en laboratorio refleje la capacidad real del modelo al enfrentarse a pacientes en la práctica médica diaria.

9 Entregables Digitales y Enlaces en Línea

Para garantizar la máxima transparencia, reproducibilidad y agilidad de evaluación por parte del docente, el proyecto completo (código fuente ejecutable, gráficos, tabla de decisiones y dataset) se encuentra alojado y disponible en las siguientes plataformas oficiales:

Accesos Oficiales en Línea (Ejecución Interactiva):

- **Google Colab (Cuaderno Interactivo en la Nube):**
  Abrir Cuaderno en Google Colab (Clic Aquí)
  Permite la inspección directa de cada bloque de código, outputs y ejecuciones en la nube de Google.

- **Repositorio Público de GitHub:**
  https://github.com/Elnuget/taller-preprocesamiento-heart-disease
  Contiene el historial de versiones, el archivo `.ipynb` estructurado y el dataset clínico `Heart-Disease-Dirty.csv`.

- **Archivos Adjuntos en el Buzón de Brightspace:**
  `Taller_Preprocesamiento_Heart_Disease_Carlos_Angulo.ipynb`
  `Angulo_Carlos_Taller_Preprocesamiento_Base_Datos_Grupo4.pdf`

Declaración de Autoría: El presente trabajo fue desarrollado, ejecutado y documentado íntegramente por **Carlos Alberto Angulo Pizarro** (Group 4).